

一、数据清洗与特征工程

1.1 数据清洗

表格

字段	处理方案	说明
Age	均值填充缺失值	缺失样本数量较少
Cabin	删除该列	缺失占比极高，有效信息太少
Embarked	众数填充缺失值	仅 1 条缺失记录
PassengerId、Name、Ticket	直接删除	和生存预测无关，无预测价值

1.2 特征处理

1. 数值特征标准化
 - 选择 `StandardScaler` (Z-score 标准化)，不使用 `MinMax` 归一化
 - 原因：`Fare` 票价存在极端高值（富人样本）。`MinMax` 归一化会被极值挤压，大部分样本压缩到狭小区间；`StandardScaler` 仅将异常值转为偏大 / 偏小分数，对异常值更稳健。
2. 类别特征编码
 - `Embarked`：独热编码
 - `Sex`：标签编码
3. 构造新特征

```
# 家庭人数 = 兄弟姐妹+配偶 + 父母+子女 + 自己
FamilySize = SibSp + Parch + 1
```

⚠ 重要原则：预处理必须在训练集拟合，再对训练集、测试集分别转换，防止数据泄露！

二、模型结构、损失函数、优化器与超参数

2.1 完整流程

1. 读取数据集，划分训练集、测试集
2. 数据清洗 + 特征预处理（规避数据泄露）

- 3. 数据转为张量，构建 Dataset + DataLoader
- 4. 搭建全连接神经网络
- 5. 定义损失函数、优化器、学习率策略、正则化
- 6. 训练循环：前向传播 → 计算损失 → 反向传播 → 更新权重
- 7. 模型验证：每若干轮在测试集上计算准确率
- 8. 可视化训练损失、准确率变化曲线

2.2 损失函数：二元交叉熵

任务为二分类（存活 1 / 死亡 0）

- 模型输出 logits，经过 sigmoid 得到存活概率
- 交叉熵：衡量模型预测概率分布和真实标签分布之间的差距
- 对比 MSE：交叉熵梯度特性更好，训练更容易收敛；交叉熵越小，预测结果越接近真实标签。

2.3 优化器：Adam

优点

- 自适应学习率：为不同参数自动调整更新幅度
- 利用历史梯度信息，收敛速度更快，震荡更小

核心两行代码：

```
loss.backward() # 反向传播：只计算梯度，不更新权重
optimizer.step() # 使用梯度，更新网络参数
```

2.4 超参数配置

表格

参数	值
网络层数	3 层全连接
网络结构	Linear(input_dim,16) → Dropout(0.2) → Linear(16,8) → Dropout(0.2) → Linear(8,1)
Dropout 概率	0.2
Batch 大小	32
Epochs	50

参数	值
学习率调度	前 20 epoch: 0.001; 20 epoch 之后: 0.0005
L2 正则化 weight_decay	1e-5 (0.00001)

三、数据集划分、随机种子与实验配置

1. **划分比例**: 训练集 80%, 测试集 20%
2. **随机种子 seed=42**
 - 固定随机种子, 保证数据集划分、模型初始化每次运行结果一致, **实验可复现**
 - 可选: 分层划分, 保证训练集、测试集中存活 / 死亡样本比例和原数据集保持一致

四、训练过程遇到的问题与解决方案

1. **✗ 问题**: 训练时 loss 直接降到 0。 **✓ 解决**: 不能用循环创建两个仅学习率不同的优化器, 代码写法错误导致模型异常。
2. **✗ 问题**: 初期误以为手动给模型两次数据就算划分数据集。 **✓ 解决**: 使用代码自动切分训练 / 测试集; 推荐分层划分, 平衡正负样本; 固定随机种子, 实验更科学。
3. **✗ 问题**: 损失函数选错, 模型不收敛。 **✓ 解决**: 二分类任务选用二元交叉熵, 不能随意使用 MSE。
4. **✗ 问题**: 参考图像深度学习教程 (小土堆), 图像任务和表格数据任务差异大; 网上部分代码基于旧版 PyTorch, 存在 API 变更。 **✓ 解决**: 区分表格数据与图像数据建模思路; 查阅官方文档适配新版本 PyTorch。
5. **✗ 问题**: Pandas、PyTorch 代码熟练度不足。 **✓ 解决**: 增加代码复现练习, 逐行理解每一步操作。

五、实验结果、误差分析与心得体会

1. **模型指标**: 测试集准确率稳定在 80% 左右
2. **正则效果**: 使用 L2 正则 + Dropout 双重抑制过拟合, 降低模型在训练集上的记忆效应
3. **模型瓶颈**: 调参后准确率很难继续提升
4. **误差来源分析**
 - 数据集本身信息量有限, 部分影响生存的因素没有记录
 - 现有特征和生存标签的相关性已经挖掘到上限, 新增特征很难进一步提升效果
5. **泛化表现**: 测试集准确率低于训练集, 属于正常现象 (模型在未见过的数据上表现会下降)
6. **心得**
 - 表格数据项目中, **数据清洗、特征工程往往比调参更重要**
 - 必须重视数据泄露问题, 预处理逻辑不能搞错

- 神经网络不是万能的，数据集质量决定了模型性能上限